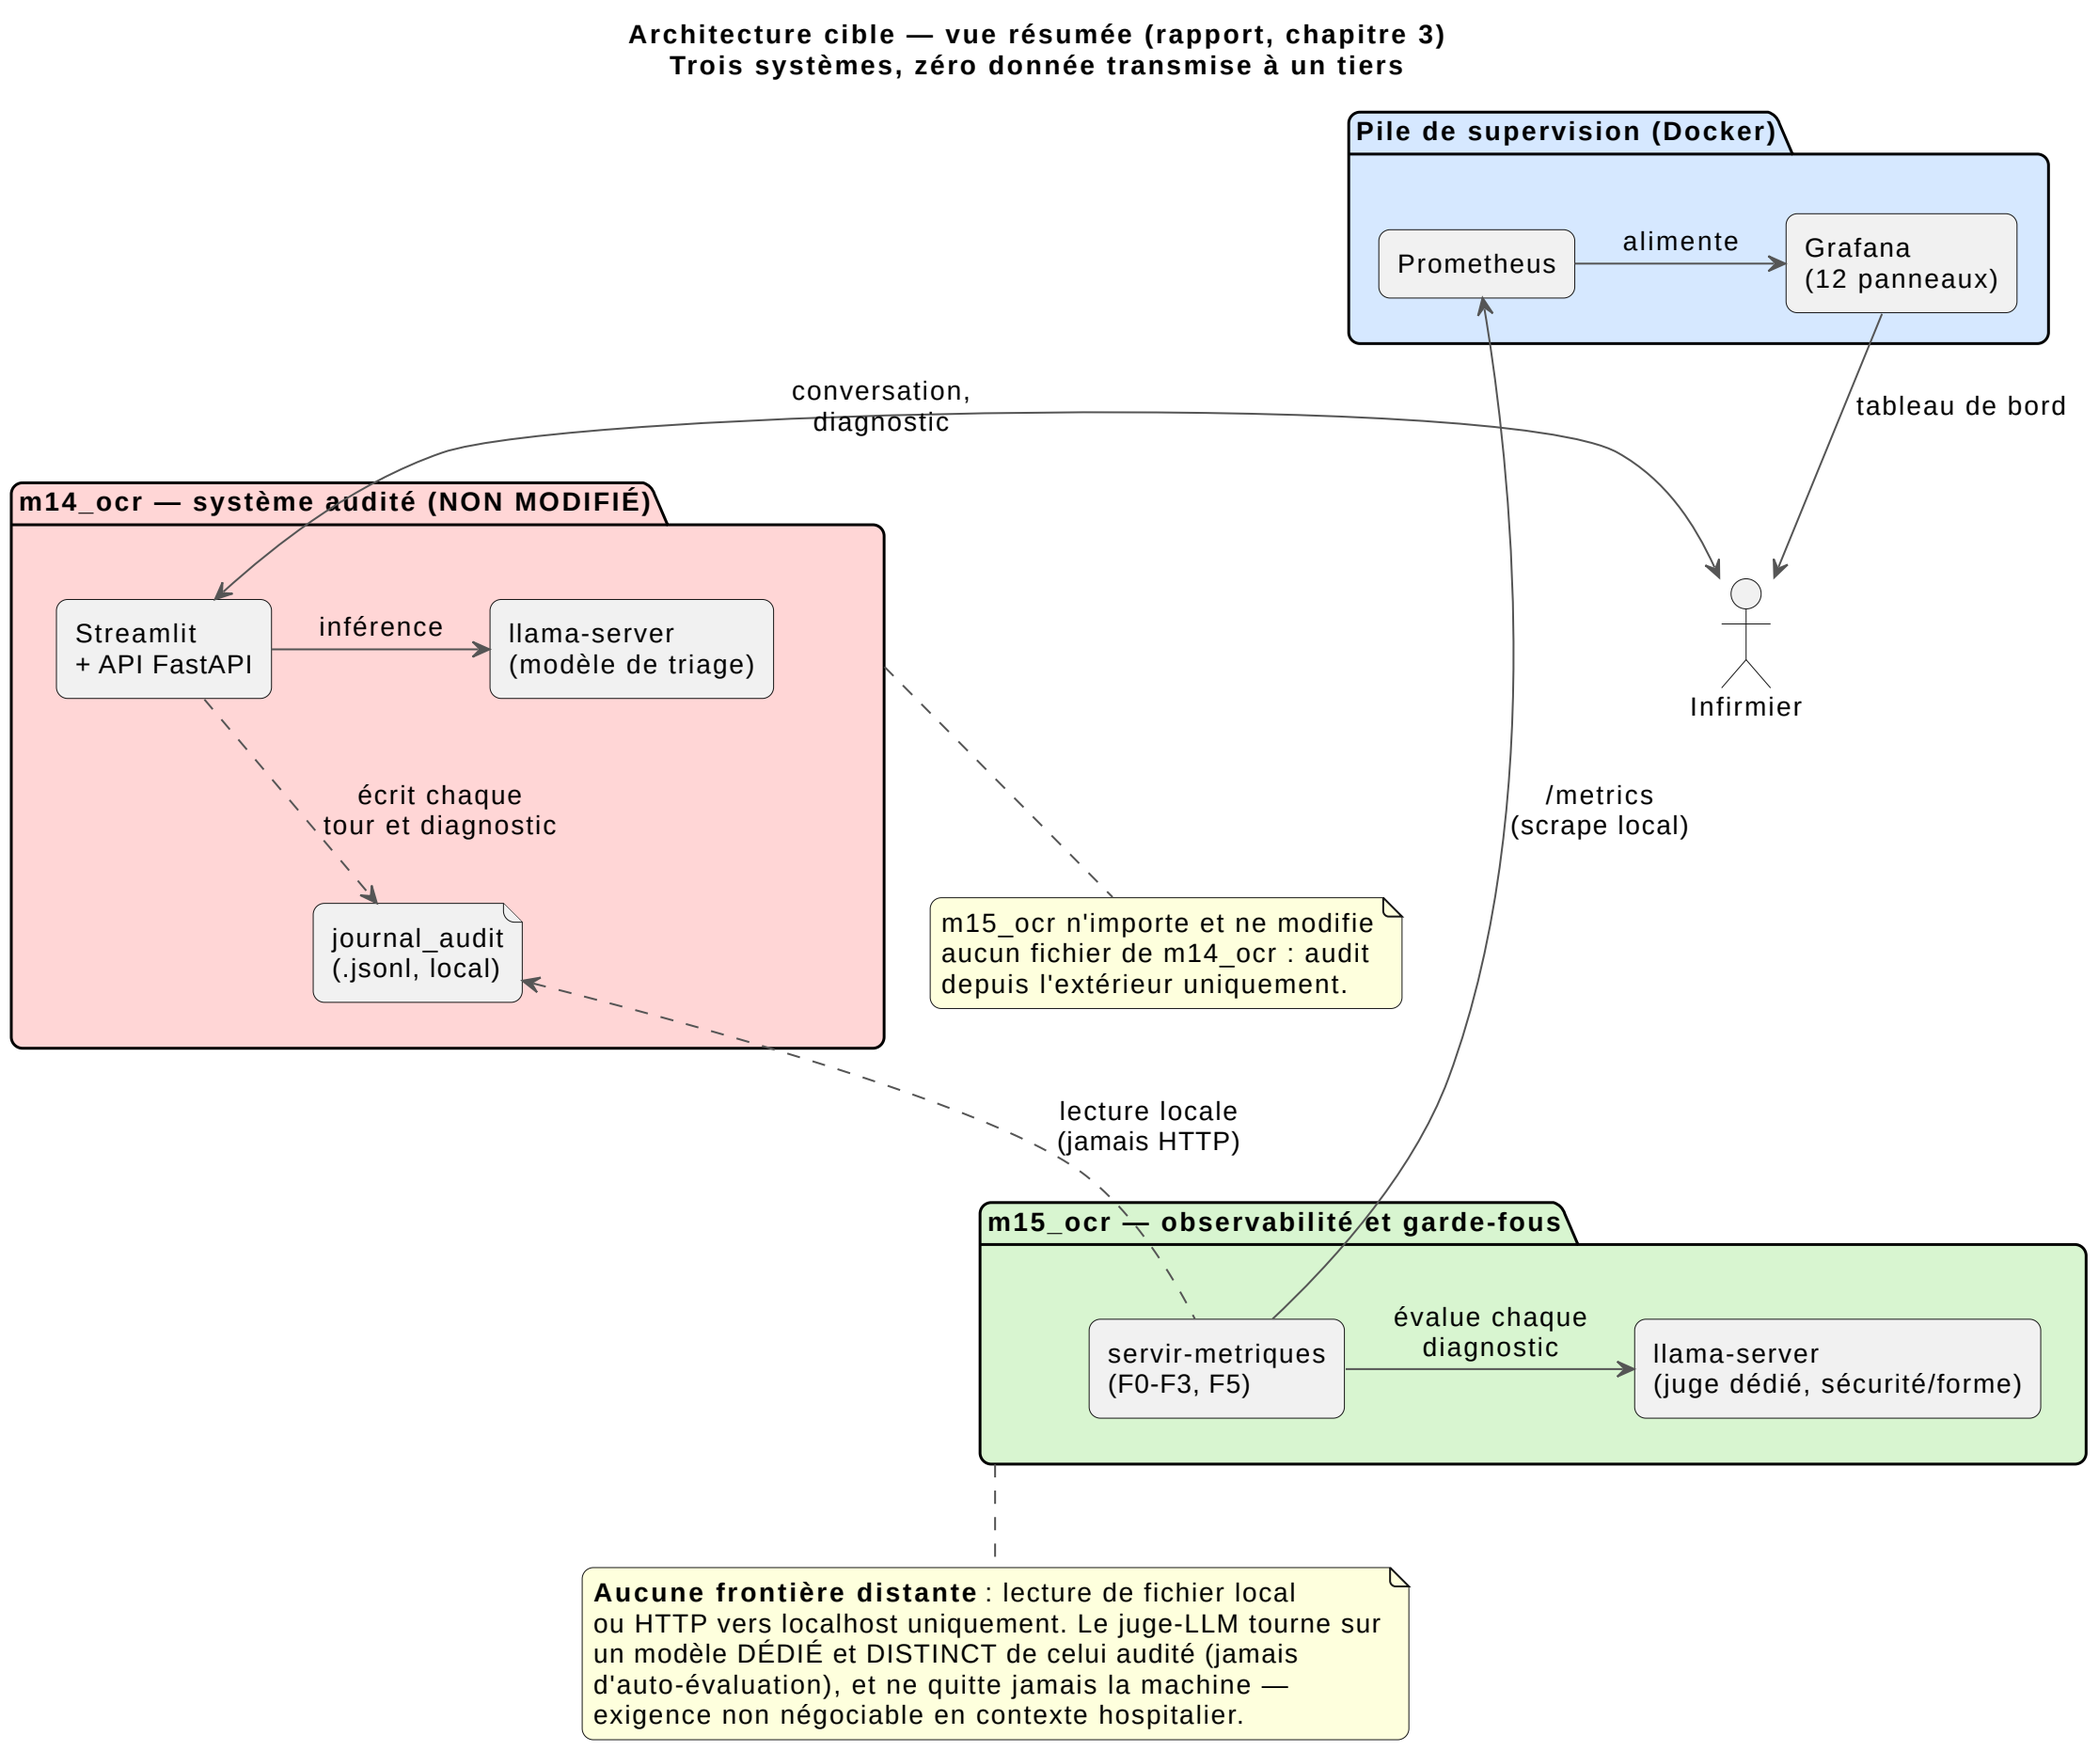
Architecture cible — vue résumée (rapport, chapitre 3)
Trois systèmes, zéro donnée transmise à un tiers
Pile de supervision (Docker)
Prometheus
alimente
Grafana
(12 panneaux)
tableau de bord
conversation,
diagnostic
m14_ocr — système audité (NON MODIFIÉ)
Streamlit
+ API FastAPI
inférence
llama-server
(modèle de triage)
Infirmier
écrit chaque
tour et diagnostic
/metrics
(scrape local)
journal_audit
(.jsonl, local)
m15_ocr n'importe et ne modifie aucun fichier de m14_ocr : audit depuis l'extérieur uniquement.
lecture locale
(jamais HTTP)
m15_ocr — observabilité et garde-fous
servir-metriques
(F0-F3, F5)
évalue chaque
diagnostic
llama-server
(juge dédié, sécurité/forme)
Aucune frontière distante : lecture de fichier local ou HTTP vers localhost uniquement. Le juge-LLM tourne sur un modèle DÉDIÉ et DISTINCT de celui audité (jamais d'auto-évaluation), et ne quitte jamais la machine — exigence non négociable en contexte hospitalier.