Carte des métriques — domaine du triage CHSA
Conversation Question/Réponse Diagnostic

construite (en production)
dérivable (donnée dispo, logique à écrire)
indisponible (nécessite F4, hors périmètre)

C — CONVERSATION
(ServiceAnalyseConversations, F3)

C1 Nb de tours avant diagnostic
C2 Temps jusqu'au diagnostic
C3 Taux de reformulation
C4 Durée totale de la conversation (écartée, redondante avec C2)
C5 Taux d'abandon (jamais de diagnostic)
C6 Taux d'échec par conversation
C7 Efficacité clinique du diagnostic

alimente le prochain tour

R — QUESTION / RÉPONSE
(ServiceInstrumentationJournal, F2)

R1 Latence de la réponse
R2 Tokens de sortie
R3 Tokens / seconde
R4 Longueur de la question générée
R5 Pertinence (heuristique)
R6 Pertinence (RAGAS / juge)
R7 Position du tour dans la conversation
R8 Dégénérescence / boucle
R9 Volume de requêtes
R10 Taux d'erreur

clôture par le diagnostic

D — DIAGNOSTIC
(ServiceInstrumentationJournal, F2 / futur F4)

D1 Conformité du format
D2 Latence du diagnostic
D3 Tokens de sortie
D4 Niveau ESI
D5 Longueur du raisonnement
D6 Distribution des niveaux ESI
D7 Cas ESI urgents (1-2) et leur latence

comparé entre configurations

X — TRANSVERSALES
(toutes couches confondues)

X1 Comparaison entre configurations
X2 Coût estimé cumulé
X3 Carte de chaleur de l'activité
X4 Latence inférence pure vs HTTP totale