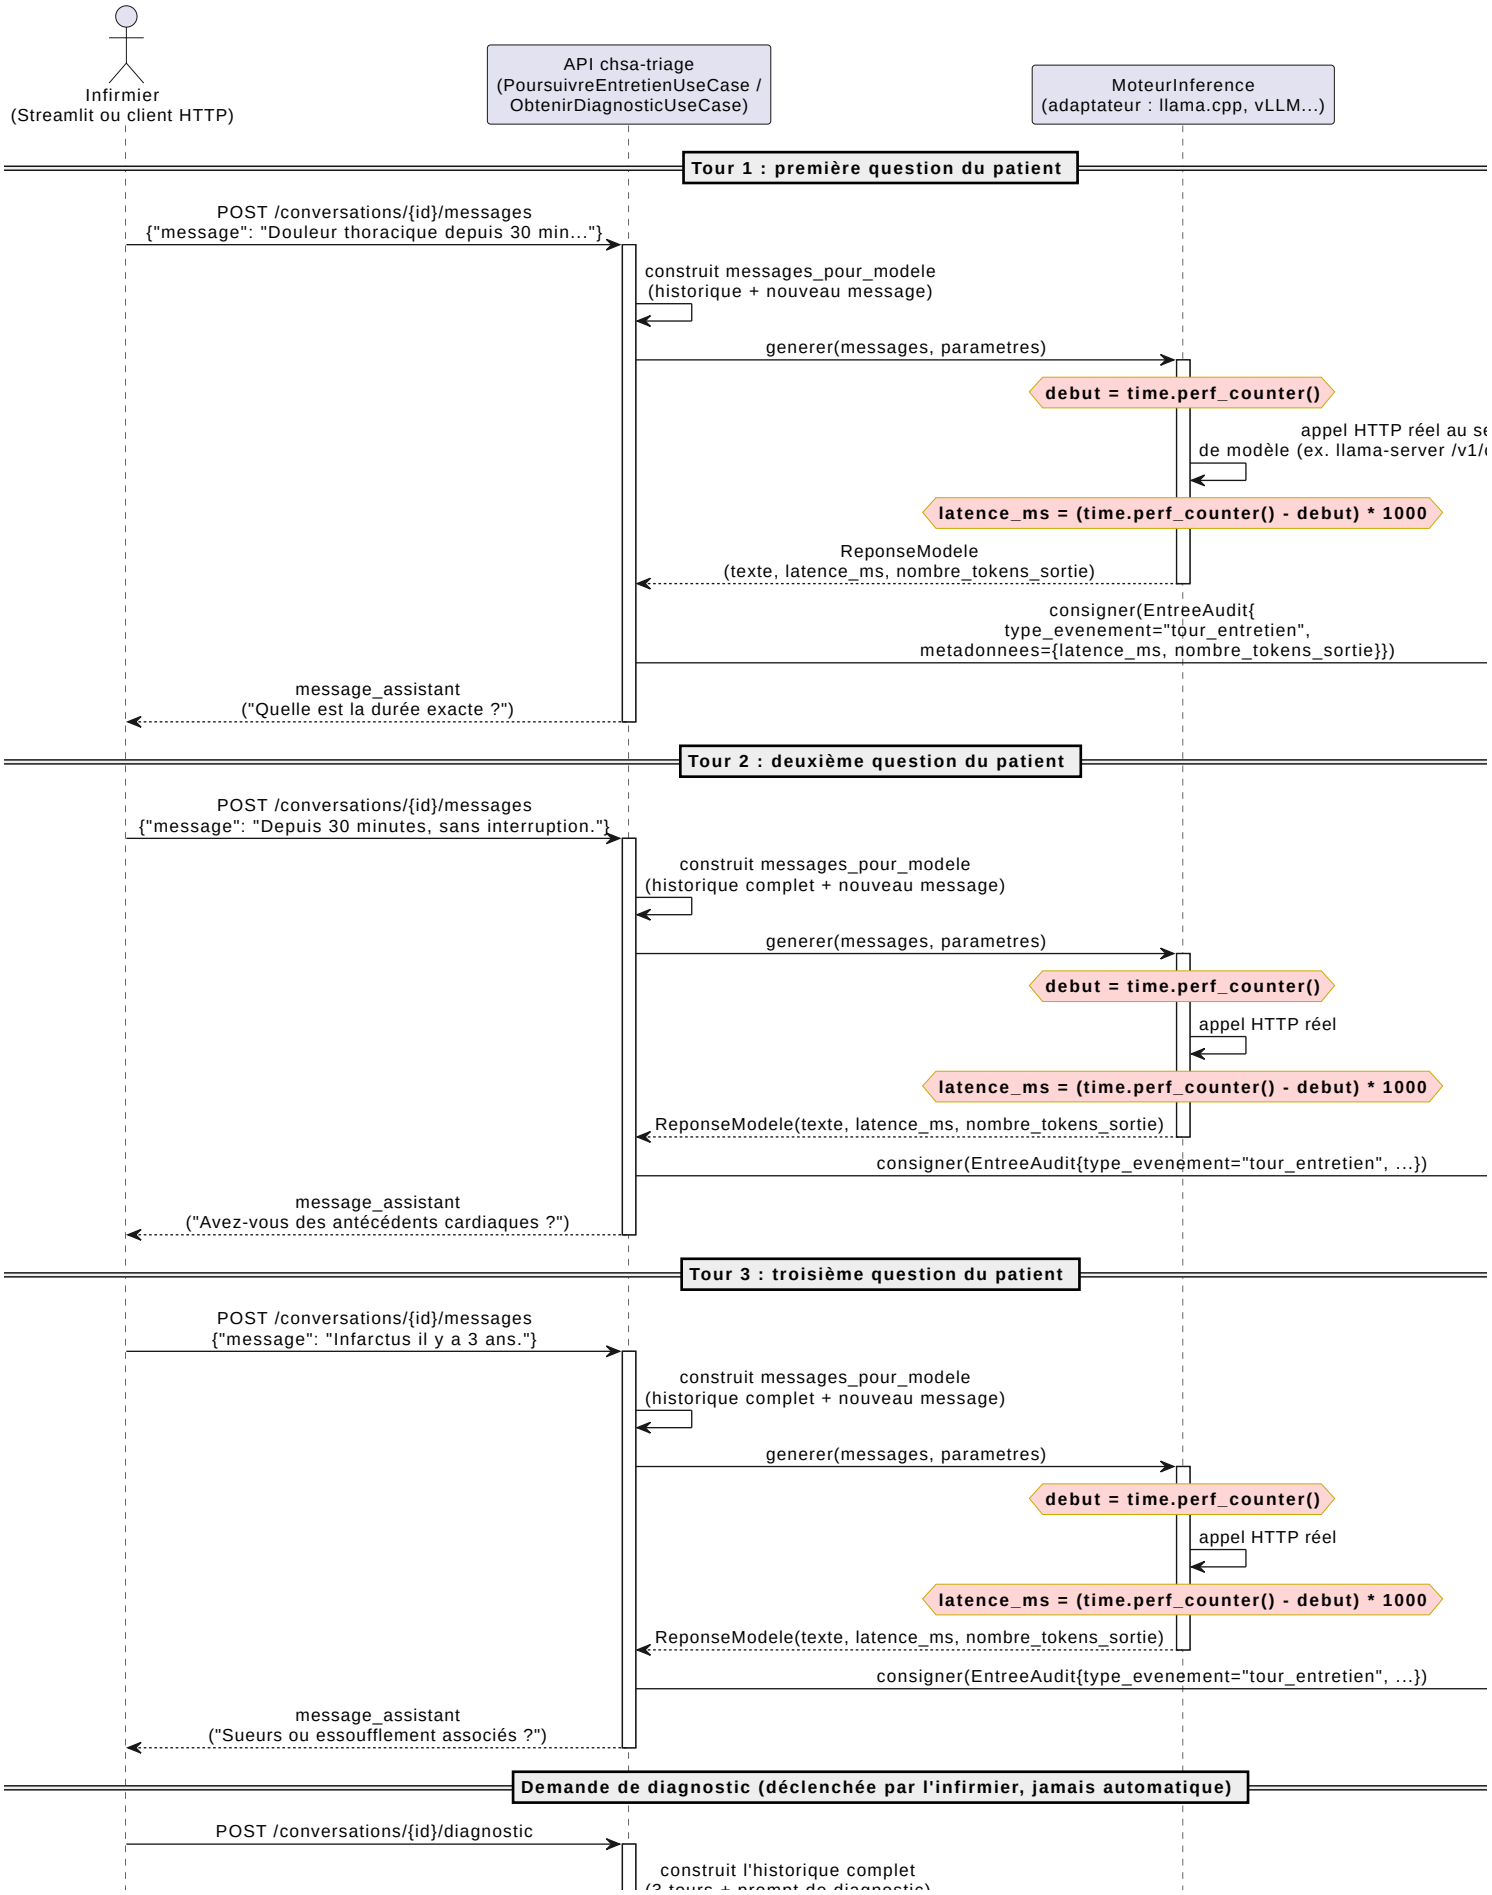
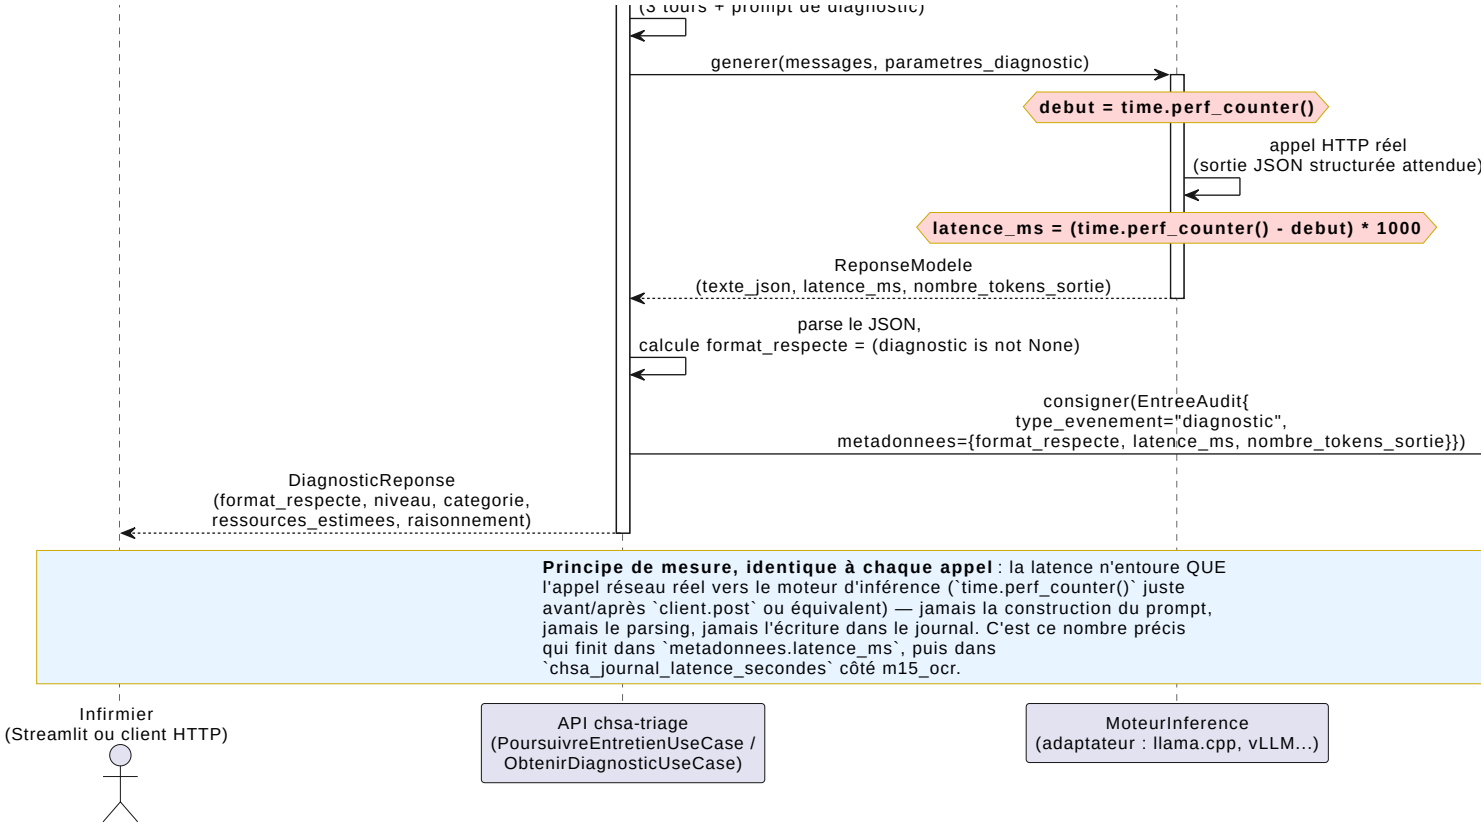
Exemple générique — Conversation type (3 tours + diagnostic)
chsa-triage (m14_ocr) : où et comment chaque latence est mesurée




(3 tours + prompt de diagnostic)
generer(messages, parametres_diagnostic)
debut = time.perf_counter()
appel HTTP réel
(sortie JSON structurée attendue)
latence_ms = (time.perf_counter() - debut) * 1000
ReponseModele
(texte_json, latence_ms, nombre_tokens_sortie)
parse le JSON,
calcule format_respecte = (diagnostic is not None)
consigner(EntreeAudit{
type_evenement="diagnostic",
metadonnees={format_respecte, latence_ms, nombre_tokens_sortie}})
DiagnosticReponse
(format_respecte, niveau, categorie,
ressources_estimees, raisonnement)
Principe de mesure, identique à chaque appel : la latence n'entoure QUE l'appel réseau réel vers le moteur d'inférence (`time.perf_counter()` juste avant/après `client.post` ou équivalent) — jamais la construction du prompt, jamais le parsing, jamais l'écriture dans le journal. C'est ce nombre précis qui finit dans `metadonnees.latence_ms`, puis dans `chsa_journal_latence_secondes` côté m15_ocr.
Infirmier
(Streamlit ou client HTTP)
API chsa-triage
(PoursuivreEntretienUseCase /
ObtenirDiagnosticUseCase)
MoteurInference
(adaptateur : llama.cpp, vLLM...)