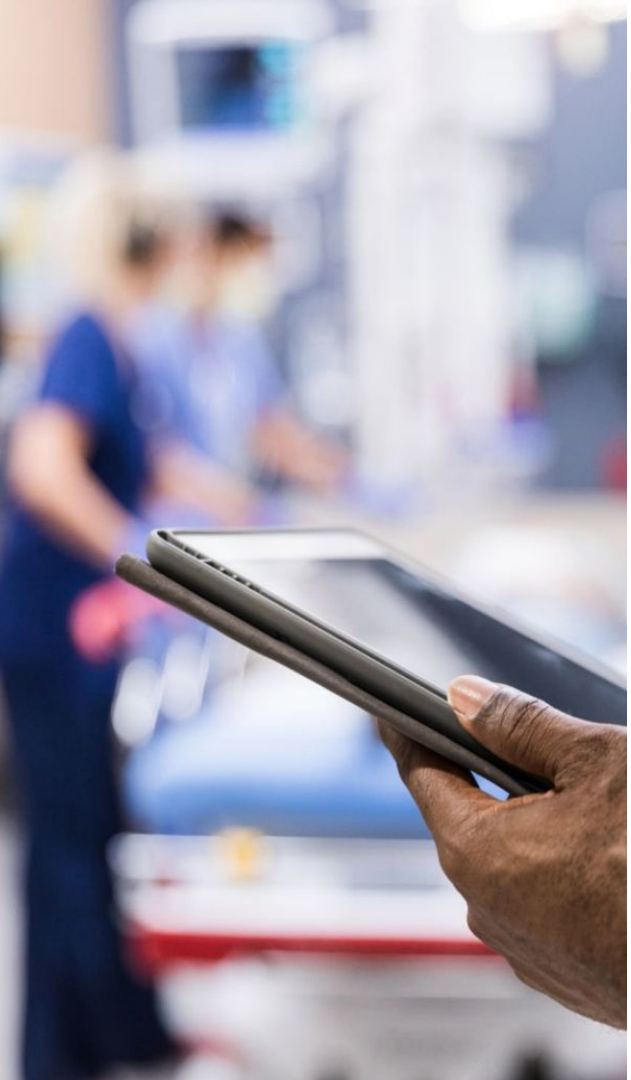


Centre Hospitalier
Saint-Aurélien (CHSA)

MODULE M15. CONDUITE DE PROJET AI ENGINEERING

Observabilité et garde-fous (juge-LLM) du triage médical CHSA

Auditer, instrumenter et superviser un agent IA de pré-triage, jusqu'à ses garde-fous de sécurité, sans jamais le modifier

Rafael CEREZO MARTIN

Octobre 2026

Une mission de conduite de projet, appliquée à un système IA déjà en production

Centre Hospitalier Saint-Aurélien (CHSA)

1

1. Introduction
2. Contexte
3. Diagnostic
4. Architecture cible
5. Garde-fous, Principe
6. Garde-fous, Diagramme
7. Mise en œuvre
8. Pilotage, Indicateurs
9. Pilotage, Dashboard
10. Bilan
11. Questions

CHSA Triage (m14_ocr) est un agent IA de pré-triage déjà développé, fine-tuné et certifié.
Ce projet M15 l'utilise comme terrain réel pour appliquer les exigences de conduite de projet AI Engineering.

Exigence de la mission M15	Comment ce projet y répond
Analyser le besoin métier et auditer l'existant	Audit de m14_ocr : angle mort identifié — aucune observabilité native (ch. 1-2)
Proposer une architecture technique cible, argumentée	Architecture à 3 systèmes (audité / observabilité / garde-fous), zéro frontière distante (ch. 3)
Définir une stratégie de mise en œuvre et d'industrialisation	Livraison itérative F0 ⟶ F5, Docker local, gratuit (ch. 4)
Mettre en place un pilotage et un suivi de projet	Tableau de bord Grafana (12 panneaux) + garde-fou juge-LLM rétrospectif (ch. 5)
Conclure, objectiver les limites et recommander la suite	Bilan assumé (limites C5/C7 documentées), feuille de route F4 (ch. 6)

1. Introduction
2. Contexte
3. Diagnostic
4. Architecture cible
5. Garde-fous, Principe
6. Garde-fous, Diagramme
7. Mise en œuvre
8. Pilotage, Indicateurs
9. Pilotage, Dashboard
10. Bilan
11. Questions

Contexte

Le projet précédent : CHSA Triage (m14_ocr)

- **Agent IA de pré-triage médical** : aide l'infirmier à recueillir les symptômes, puis propose un diagnostic structuré (niveau ESI, catégorie, ressources estimées)
- **Modèle Qwen3-1.7B, fine-tuné** SFT puis DPO sur des cas de triage
- **Architecture hexagonale** (ports et adaptateurs): même discipline reprise dans m15_ocr
- **4 configurations de déploiement** : 2 distantes (vLLM, GPU) + 2 locales (GGUF/llama.cpp, Transformers+PEFT)
- **Déjà soumis et validé en certification**. n'est pas remis en cause par M15

Chiffres clés m14_ocr

- Qwen3-1.7B-Base + LoRA (DPO)
- Architecture hexagonale (domain / application / infrastructure / interfaces)
- staging1 : llama.cpp, Q4_K_M, CPU, gratuit
- staging2 : Transformers + PEFT, bf16, CPU, comparaison hors-ligne
- Journal d'audit JSONL natif (tour_entretien, diagnostic, diagnostic_reformule, echec_inference)

Diagnostic

Un angle mort assumé par le projet lui-même

Dans le code de m14_ocr, port JournalAudit :

« jamais une stack d'observabilité lourde »

- Une décision de périmètre assumée, pas un oubli, mais un vrai manque pour un système IA en contexte médical
- Piloter un agent de triage sans visibilité sur ses performances, ses erreurs et sa fiabilité = un risque
- La conduite de projet AI Engineering, c'est justement piloter, pas seulement construire
- → **Opportunité naturelle pour M15** : combler ce manque, sans toucher au système validé

Centre Hospitalier
Saint-Aurélien (CHSA)

4

1. Introduction
2. Contexte
3. Diagnostic
4. Architecture cible
5. Garde-fous, Principe
6. Garde-fous, Diagramme
7. Mise en œuvre
8. Pilotage, Indicateurs
9. Pilotage, Dashboard
10. Bilan
11. Questions

Trois systèmes, zéro donnée transmise à un tiers

1. Système Audité

Assistant de pré-triage m14_ocr.

- **Modèle:** Qwen3-1.7B DPO (port 8000).
- **Journal:** Fichier JSONL natif d'audit.
- **État:** Code inchangé à l'octet près.

2. Pile Observabilité

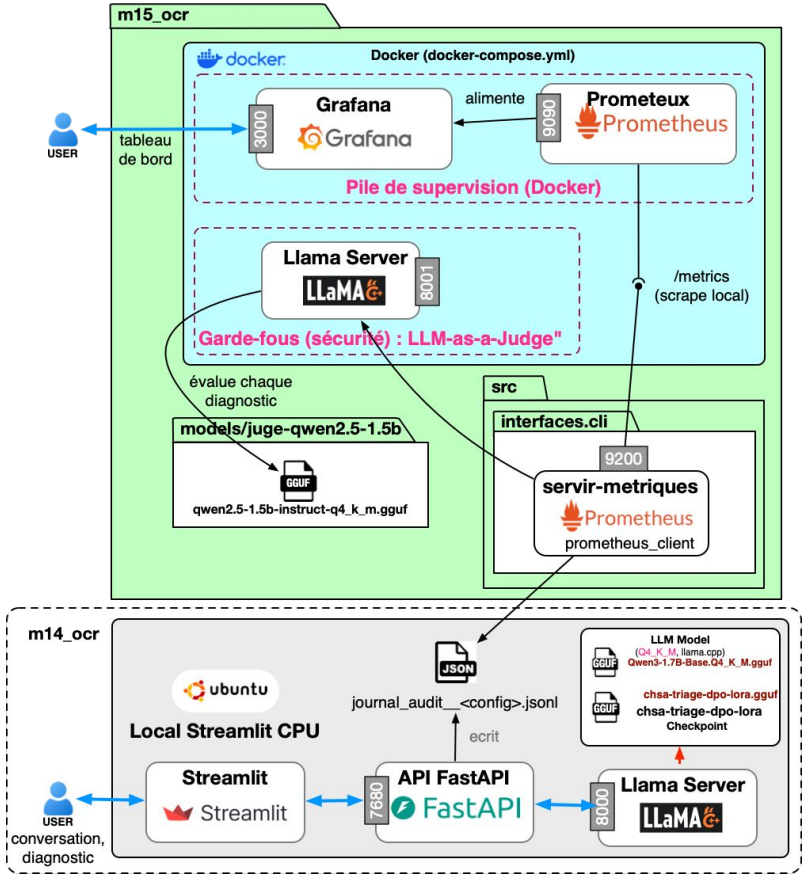
Supervision sous Docker Compose.

- **Grafana:** 12 panneaux de pilotage (port 3000).
- **Prometheus:** Scraping local toutes les 15s (port 9090).
- **Service Python:** Expose /metrics (port 9200).

3. Garde-fous (Juge-LLM)

Évaluation rétrospective locale.

- **Modèle:** Qwen2.5-1.5B-Instruct (port 8001).
- **Analyse:** Forme et sécurité du diagnostic.
- **Coût:** 0 € (Exécution CPU local).



Architecture Hexagonale

4

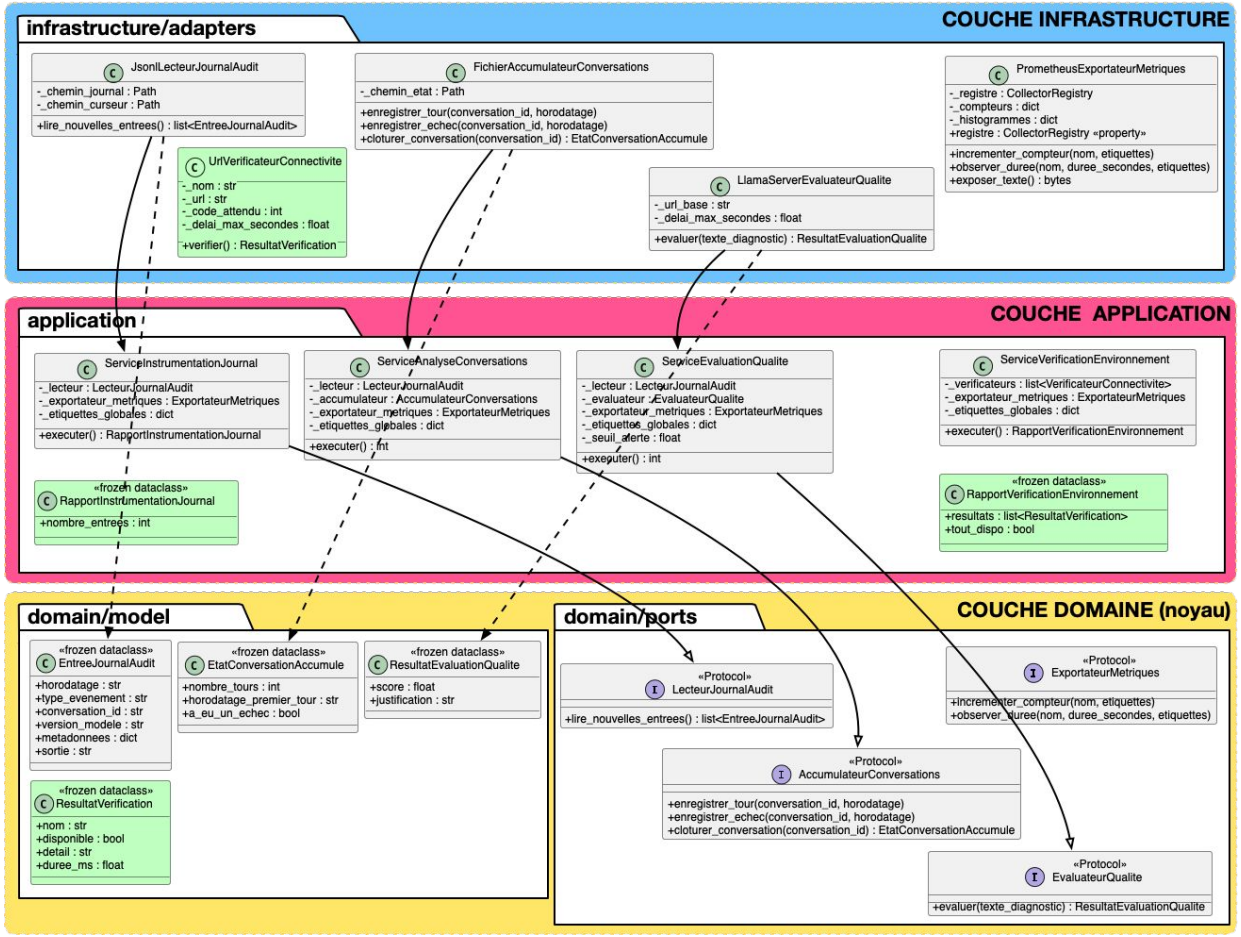
1. Introduction
2. Contexte
3. Diagnostic
4. Architecture cible
5. Garde-fous, Principe
6. Garde-fous, Diagramme
7. Mise en œuvre
8. Pilotage, Indicateurs
9. Pilotage, Dashboard
10. Bilan
11. Questions

Principe clé :
Dépendances à sens unique, zéro modification du système audité (m14_ocr).

Domaine (Noyau) :
Logique métier isolée et indépendante des technologies externes.

Application :
Orchestration des cas d'usage (services d'analyse et d'instrumentation).

Infrastructure / Adapteurs : Connexions concrètes (lecteur JSONL, Prometheus, Llama-server).

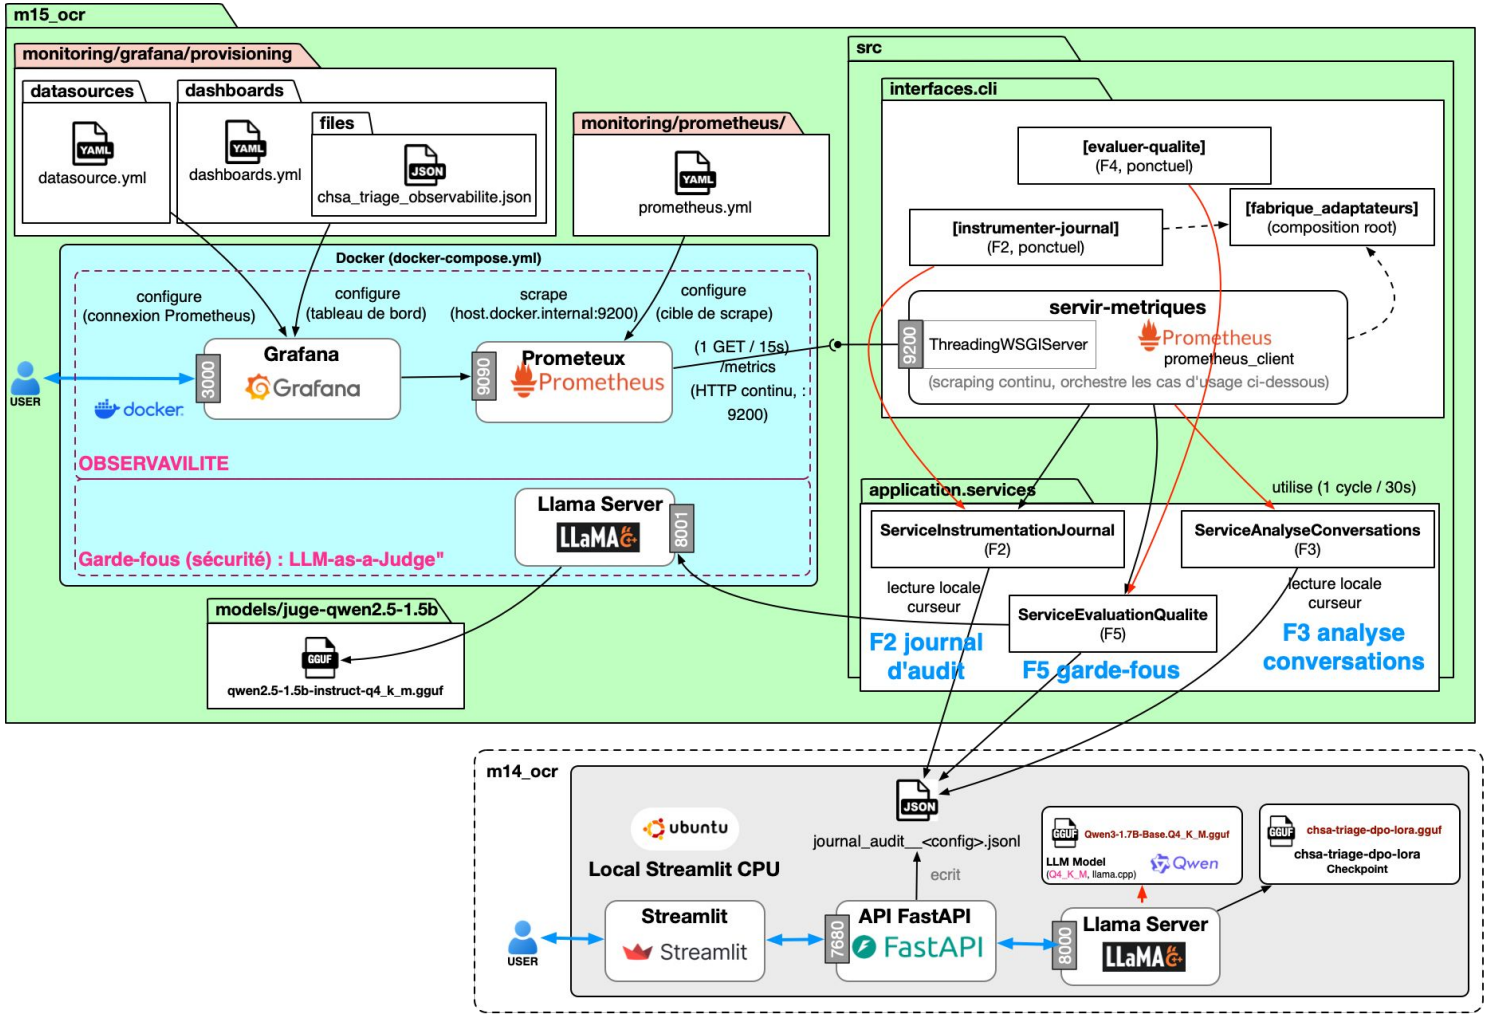


Centre Hospitalier
Saint-Aurélien (CHSA)

4

1. Introduction
2. Contexte
3. Diagnostic
4. Architecture cible
5. Garde-fous, Principe
6. Garde-fous, Diagramme
7. Mise en œuvre
8. Pilotage, Indicateurs
9. Pilotage, Dashboard
10. Bilan
11. Questions

ARCHITECTURE CIBLE



1. Introduction
2. Contexte
3. Diagnostic
4. Architecture cible
5. Garde-fous, Principe
6. Garde-fous, Diagramme
7. Mise en œuvre
8. Pilotage, Indicateurs
9. Pilotage, Dashboard
10. Bilan
11. Questions

GARDE-FOUS, Principe

Un juge-LLM dédié, local et gratuit

Jamais le système audité lui-même

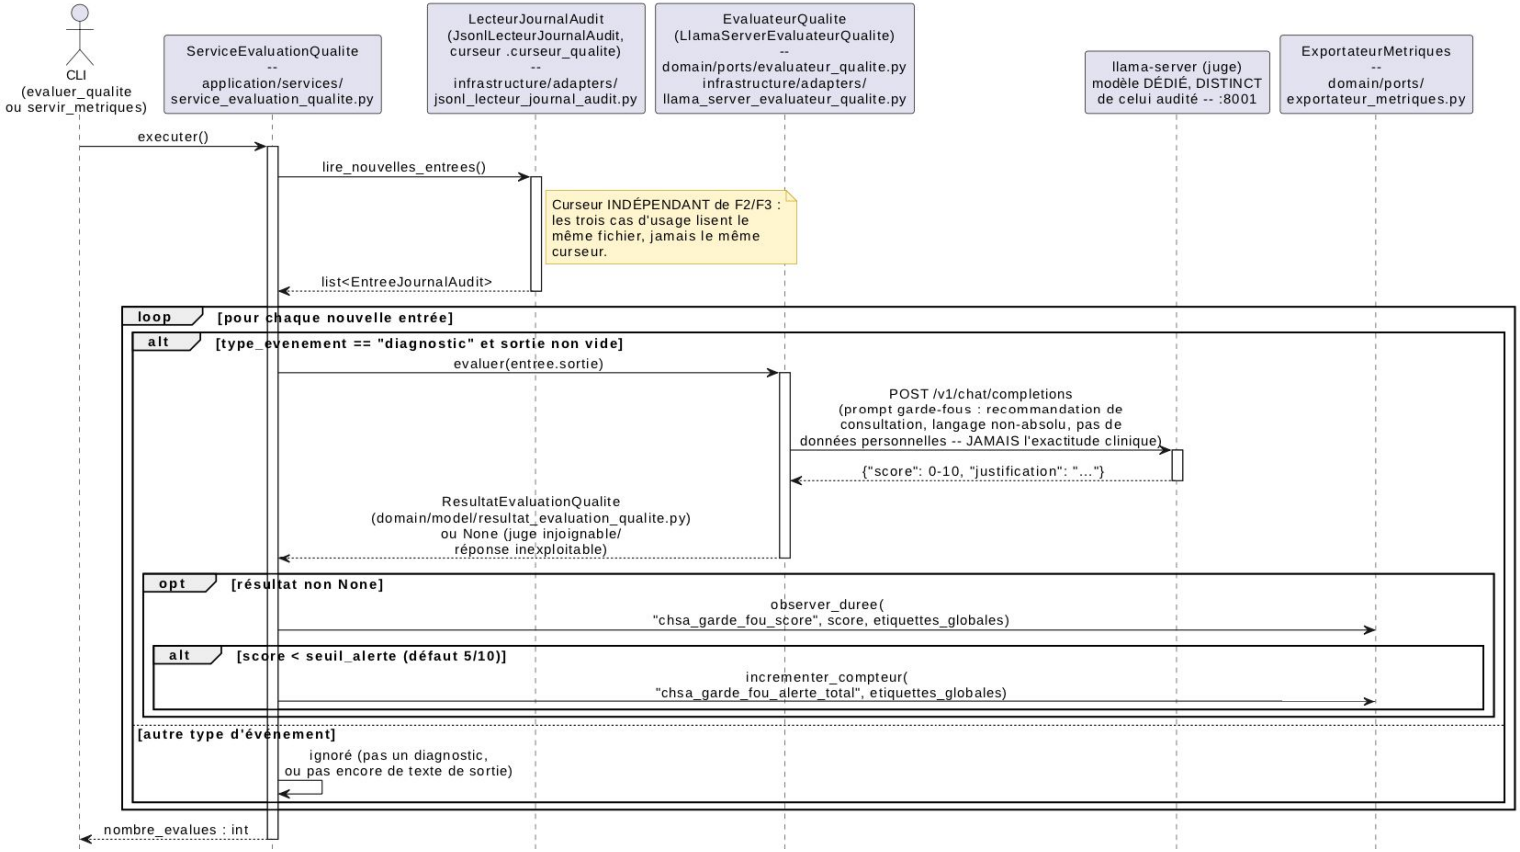
- Pourquoi : évaluer la FORME et la SÉCURITÉ de chaque diagnostic, jamais sa pertinence clinique.
- Qwen2.5-1.5B-Instruct, local et gratuit, llama-server dédié sur :8001, distinct du modèle audité (:8000).
- Vérifie : recommandation de consultation, langage non absolu, absence de données personnelles.
- Seuil d'alerte configurable (score < 5/10 par défaut).

RÉTROSPECTIF, PAS PRÉVENTIF

Ce cycle tourne après que l'infirmier a déjà reçu la réponse.
Sa valeur est la

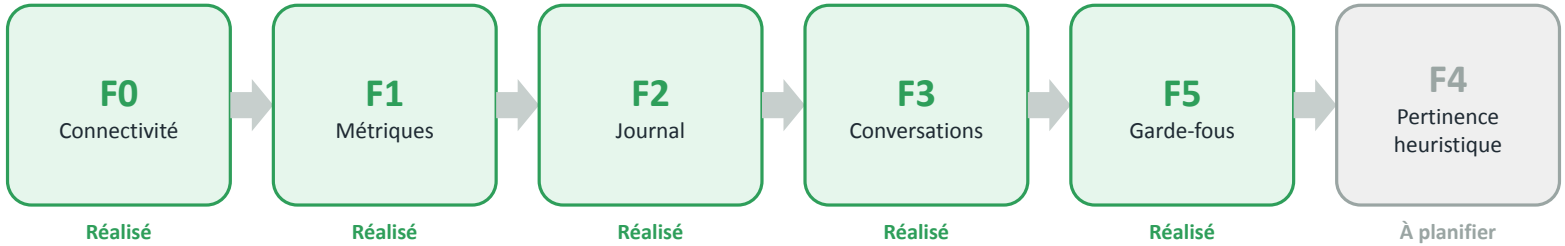
m15_ocr — Séquence : ServiceEvaluationQualite.executer() (F5, garde-fous)

GARDE-FOU RÉTROSPECTIF, PAS PRÉVENTIF



1. Introduction
2. Contexte
3. Diagnostic
4. Architecture cible
5. Garde-fous, Principe
6. Garde-fous, Diagramme
7. Mise en œuvre
8. Pilotage, Indicateurs
9. Pilotage, Dashboard
10. Bilan
11. Questions

Une livraison itérative, tranche par tranche



- Projet personnel, développeur unique, pas de cérémonie Scrum/Kanban formelle.
- Chaque tranche traverse systématiquement : développement → tests → intégration → documentation.
- Toujours le prochain cas d'usage dérivable « à moindre risque ».

PILOTAGE

Indicateurs

8

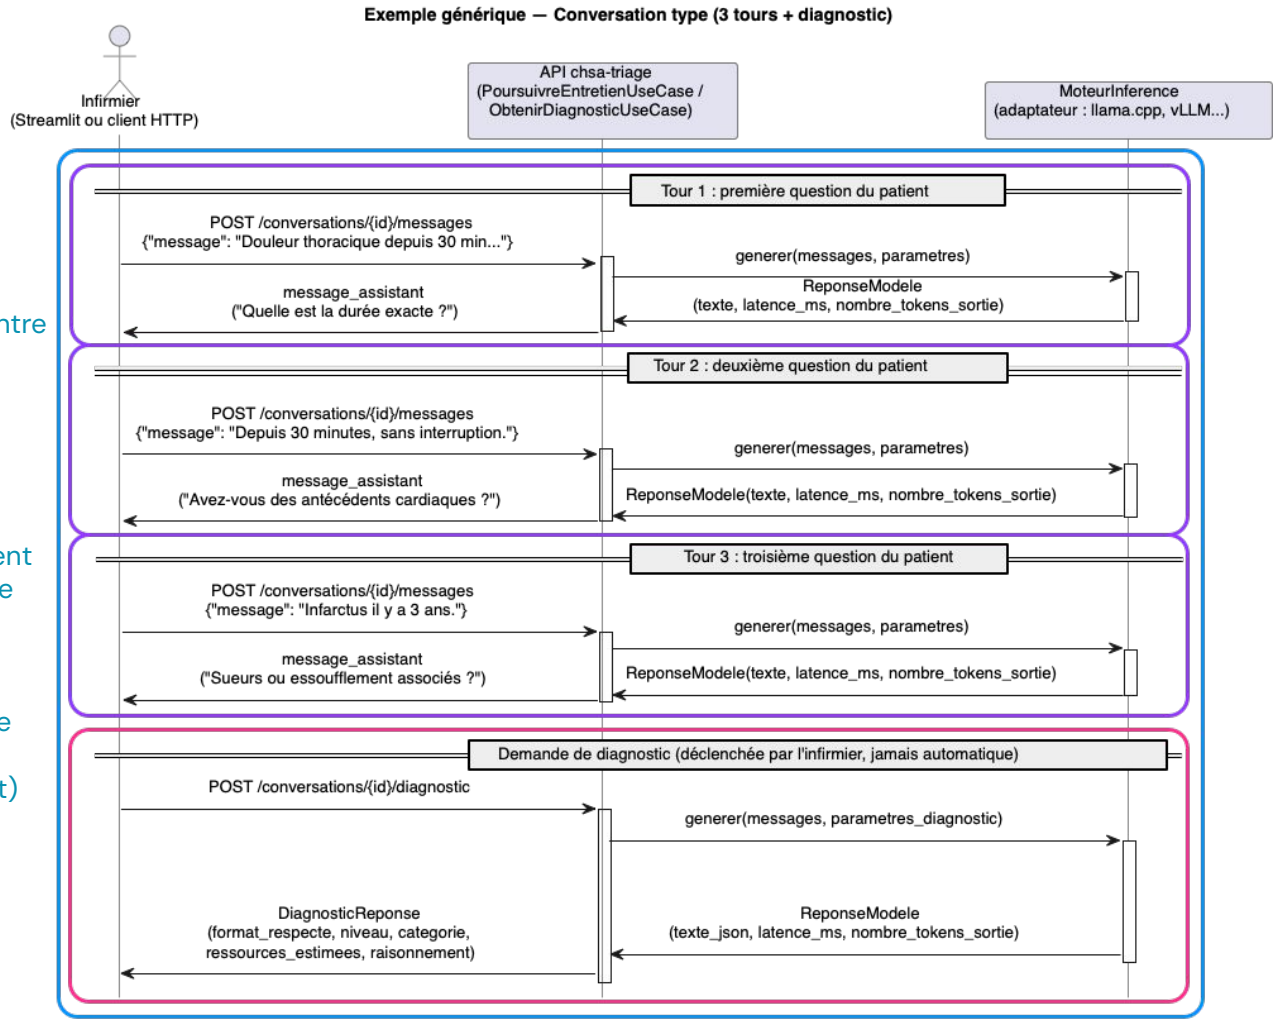
1. Introduction
2. Contexte
3. Diagnostic
4. Architecture cible
5. Garde-fous, Principe
6. Garde-fous, Diagramme
7. Mise en œuvre
8. Pilotage, Indicateurs
9. Pilotage, Dashboard
10. Bilan
11. Questions

Déroulement d'un entretien type :

Tours itératifs :
Échanges successifs entre l'infirmier et l'assistant pour affiner les symptômes (3 tours illustrés ici).

Diagnostic final :
Déclenché manuellement par l'infirmier (jamais de manière automatique).

Traçabilité :
Chaque étape consigne les métriques clés (latence, tokens, format) dans le journal d'audit.



8

1. Introduction
2. Contexte
3. Diagnostic
4. Architecture cible
5. Garde-fous, Principe
6. Garde-fous, Diagramme
7. Mise en œuvre
8. Pilotage, Indicateurs
9. Pilotage, Dashboard
10. Bilan
11. Questions

PILOTAGE

Indicateurs

Structure du Journal d'Audit (JSONL) :

Traçabilité brute : Chaque événement consigné (tour d'entretien et diagnostic) intègre des métadonnées clés (latence_ms, nombre_tokens_sortie, format_respecte) exploitées directement par le service d'instrumentation.

[type_evenement == "tour_entretien"]


```
{
  "horodatage": "2026-10-21T14:04:31.641757+00:00",
  "type_evenement": "tour_entretien",
  "conversation_id": "39ba2953-27e4-4246-accf-1ad40c798500",
  "entree": "Pas de fievre, pas de traumatisme recent.",
  "sortie": "- La pression artérielle est normale (125/83 mmHg). Le patient n'a aucun antécédent d'infarctus du myocarde ni traitement actuel pour l'hyp",
  "version_modele": "mombasstic/chsa-triage-dpo-lora",
  "metadonnees": {
    "latence_ms": 7965.360308007803,
    "nombre_tokens_sortie": 48
  }
}
```


[type_evenement == "diagnostic"]


```
{
  "horodatage": "2026-10-21T14:04:58.945744+00:00",
  "type_evenement": "diagnostic",
  "conversation_id": "39ba2953-27e4-4246-accf-1ad40c798500",
  "entree": "[{\"role\": \"user\", \"contenu\": \"Tu es un assistant de triage aux urgences qui aide un infirmier a recueillir les informations d'un patient. Pose UNE SEULE question a la fois, courte et cliniquement pertinente, en lien direct avec les symptomes deja decrits par le patient. Ne pose jamais plusieurs questions ni une liste a la fois. Ne fais aucun commentaire general, aucune explication theorique, ni aucune digression sur d'autres cas ou traitements sans rapport avec ce patient precis. Reponds uniquement par la question elle-meme, rien d'autre avant ou apres. Ne propose ni diagnostic ni niveau de priorite a ce stade : l'infirmier declenchera lui-meme le diagnostic final quand il aura juge l'entretien suffisant.\\n\\nPatient de 40 ans, cephalees intenses depuis ce matin.\"}, {\"role\": \"assistant\", \"contenu\": \"- La pression artérielle est normale (125/83 mmHg). Le patient a un antécédent d'hypertension et il prend actuellement une pilule anti-hyperlipidique\"}, {\"role\": \"user\", \"contenu\": \"Douleur pulsatile, pire a la lumiere.\"}, {\"role\": \"assistant\", \"contenu\": \"- La pression artérielle est normale (125/83 mmHg). Le patient n'a pas d'antécédent de hypertension ni traitement actuel pour l'hypertension.\"}, {\"role\": \"user\", \"contenu\": \"Pas de fievre, pas de traumatisme recent.\"}, {\"role\": \"assistant\", \"contenu\": \"- La pression artérielle est normale (125/83 mmHg). Le patient n'a aucun antécédent d'infarctus du myocarde ni traitement actuel pour l'hyp\"}]",
  "sortie": "La pression artérielle est normale (125/83 mmHg). Le patient n'a aucun antécédent d'infarctus du myocarde ni traitement actuel pour l'hypertension. La douleur pulsatile, pire à la lumière et sans fievre ou traumatisme recent indique une aortopathie avec un infarctu de mi-coronaires (IMC) probable.\n\nLe diagnostic final est donc : **AORTO-PULMONAR**",
  "version_modele": "mombasstic/chsa-triage-dpo-lora",
  "metadonnees": {
    "format_respecte": false,
    "latence_ms": 27242.9544510087,
    "nombre_tokens_sortie": 110
  }
}
```

1. Introduction
2. Contexte
3. Diagnostic
4. Architecture cible
5. Garde-fous, Principe
6. Garde-fous, Diagramme
7. Mise en œuvre
8. Pilotage, Indicateurs
9. Pilotage, Dashboard
10. Bilan
11. Questions

PILOTAGE

Indicateurs

[type_evenement == "echec_inference"]


```
{
  "horodatage": "2026-10-21T20:27:42.157730+00:00",
  "type_evenement": "echec_inference",
  "conversation_id": "a6a0a983-e19e-4d6a-9b9b-80bfa78e5d92",
  "entree": "[{\"role\": \"user\", \"contenu\": \"Tu es un assistant de triage aux urgences qui aide un infirmier a recueillir les informations d'un patient. Pose UNE SEULE question a la fois, courte et cliniquement pertinente, en lien direct avec les symptomes deja decrits par le patient. Ne pose jamais plusieurs questions ni une liste a la fois. Ne fais aucun commentaire general, aucune explication theorique, ni aucune digression sur d'autres cas ou traitements sans rapport avec ce patient precis. Reponds uniquement par la question elle-meme, rien d'autre avant ou apres. Ne propose ni diagnostic ni niveau de priorite a ce stade : l'infirmier declenchera lui-meme le diagnostic final quand il aura juge l'entretien suffisant.\\n\\nChute a velo, douleur au poignet droit, difficulte a bouger les doigts.\"}, {\"role\": \"assistant\", \"contenu\": \"- Quelle est la nature de cette blessure ? 1/2 - Comment avez-vous reconnu ce traumatisme chez le patient? 30% du bras gauche enflé et sensible à l'effort\"}, {\"role\": \"user\", \"contenu\": \"Gonflement visible, pas de deformation evidente.\"}, {\"role\": \"assistant\", \"contenu\": \"- Quels sont les signes cliniques qui vous ont conduit a suspecter une fracture ? 1/2 - Comment avez-vous reconnu ce traumatisme chez le patient? 30% du bras gauche enflé et\"}]",
  "sortie": "",
  "version_modele": "mombasstic/chsa-triage-dpo-lora",
  "metadonnees": {
    "type_evenement_origine": "diagnostic",
    "type_erreur": "ReadTimeout",
    "erreur": "timed out"
  }
}
```

Centre Hospitalier
Saint-Aurélien (CHSA)

8

1. Introduction
2. Contexte
3. Diagnostic
4. Architecture cible
5. Garde-fous, Principe
6. Garde-fous, Diagramme
7. Mise en œuvre
8. Pilotage, Indicateurs
9. Pilotage, Dashboard
10. Bilan
11. Questions

PILOTAGE

Indicateurs

Cartographie des indicateurs par niveau d'analyse :

L'étude détaillée des données permet d'isoler et structurer les métriques clés pour chaque type d'événement à superviser (Conversation, Question/Réponse et Diagnostic).

💬 Niveau CONVERSATION (Agrégé par conversation_id)

Statistique / Métrique	Provenance / Remarques
Nombre de questions avant le diagnostic	COUNT(tour_entretien) regroupé par conversation_id
Durée totale de la conversation	MAX(horodatage) - MIN(horodatage) par conversation_id
Temps jusqu'au diagnostic	horodatage(diagnostic) - horodatage(premier tour_entretien)
Taux de conversations atteignant le diagnostic	Angle mort : l'endpoint POST /conversations n'est pas audité, nous ne savons pas combien ont été initiées, seulement celles ayant au moins un tour ou un diagnostic. Sans cela, le « taux d'abandon » n'est pas calculable
Taux de reformulation (diagnostic_reformule)	Conversations avec cet événement / total des conversations avec diagnostic
Taux d'échec d'inférence par conversation	Conversations avec ≥ 1 echec_inference
« Efficacité » du diagnostic (correction clinique)	Non mesurable sans révision humaine ou jeu de données étiqueté, aucun champ du journal ne le capture

❓ Niveau QUESTION / RÉPONSE (Chaque tour_entretien)

Statistique / Métrique	Provenance / Remarques
Latence de la réponse	metadonnees.latence_ms, déjà dans chsa_journal_latence_secondes
Tokens de sortie	metadonnees.nombre_tokens_sortie, présent dans la donnée brute, pas encore instrumenté en tant que métrique propre
Tokens / seconde (debit / throughput)	$\text{nombre_tokens_sortie} / (\text{latence_ms} / 1000)$
Longueur de la question générée	Nécessite le champ sortie (texte), non capturé aujourd'hui dans notre modèle
Pertinence de la question (heuristique simple)	Nécessite sortie + une règle simple (une seule phrase ? se termine par ? ?), peu coûteux à construire, mais n'existe pas
Pertinence réelle (type RAGAS / juge)	Nouveau chantier, évaluation séparée par lots
Position du tour dans la conversation (1er, 2e...)	Trier par horodatage au sein de conversation_id
Dégénérescence / boucle de répétition	Nécessite sortie + détection de n-grammes répétés, peu coûteux, mais non construit

Niveau DIAGNOSTIC

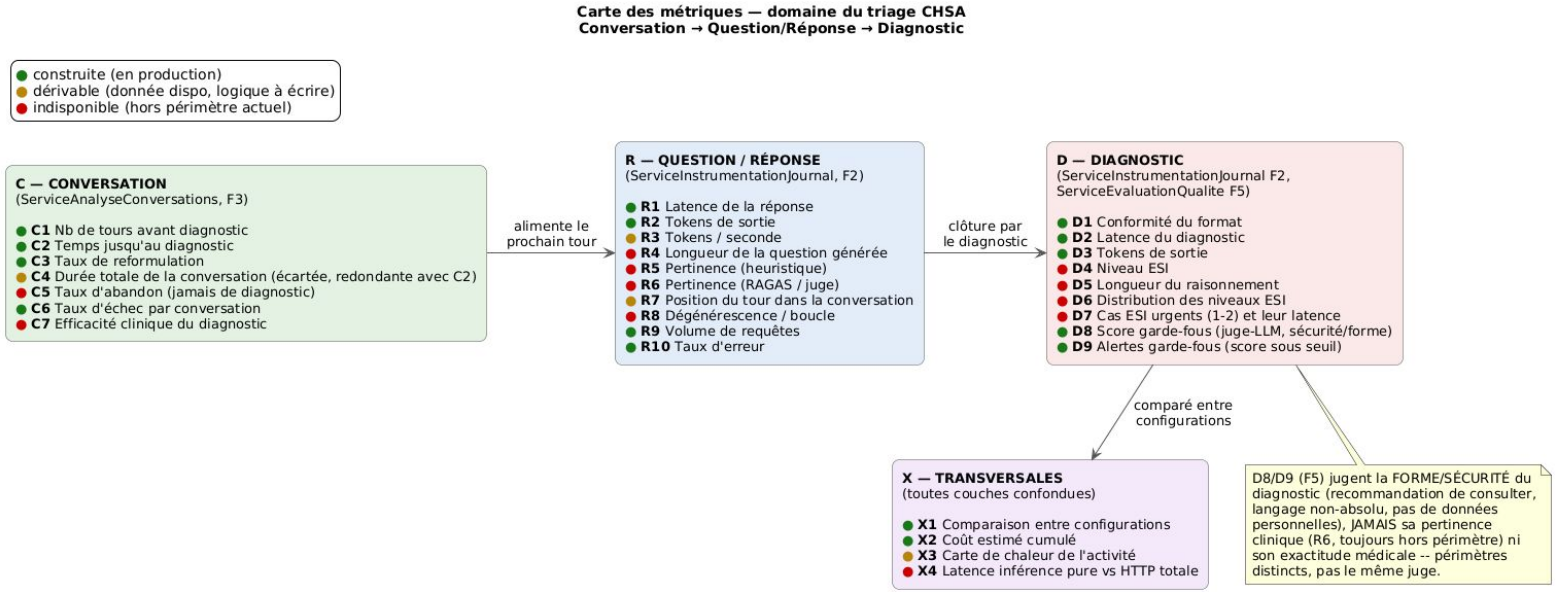
Statistique / Métrique	Provenance / Remarques
Respect du format (format_respecte)	Déjà instrumenté (chsa_diagnostic_format_respecte_total)
Latence du diagnostic	Même champ latence_ms, déjà instrumenté
Tokens de sortie du diagnostic	Comme pour tour_entretien, en brut non instrumenté
Niveau ESI / catégorie	Confirmé précédemment : non persisté dans le journal, uniquement présent dans la réponse HTTP du moment
Taux de reformulation nécessaire	Déjà couvert ci-dessus (niveau conversation)
Longueur du texte explicatif (raisonnement)	Nécessite sortie, non capturé aujourd'hui

PILOTAGE

Indicateurs

Synthèse des indicateurs et flux de causalité :

- Le schéma ci-dessous relie les quatre dimensions d'analyse et explicite la lecture des statuts (du construit au non disponible).



Indicateurs

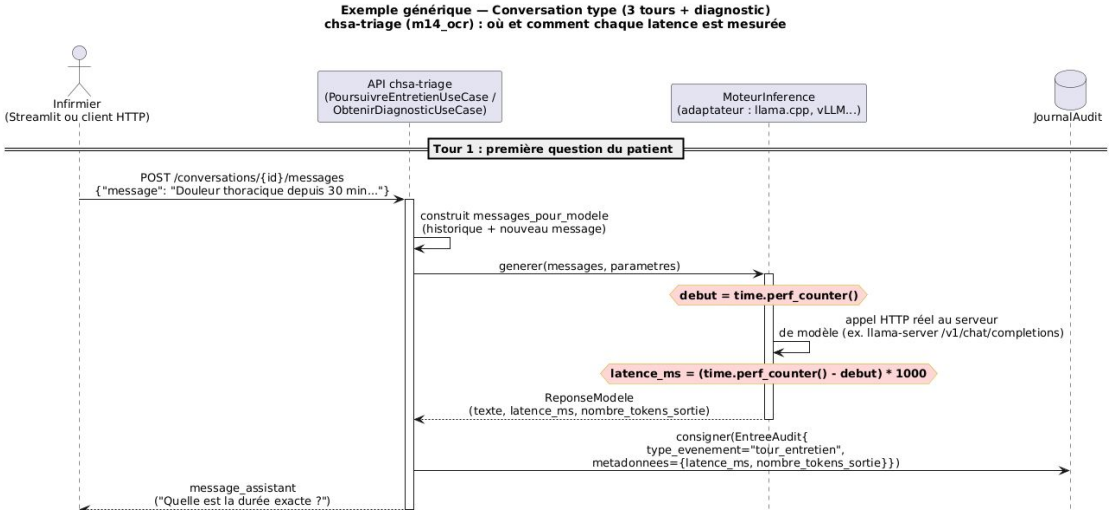
8

1. Introduction
2. Contexte
3. Diagnostic
4. Architecture cible
5. Garde-fous, Principe
6. Garde-fous, Diagramme
7. Mise en œuvre
8. Pilotage, Indicateurs
9. Pilotage, Dashboard
10. Bilan
11. Questions

RIGUEUR DE MESURE

Où et comment chaque latence est mesurée

- La latence n'entoure QUE l'appel réseau réel vers le moteur d'inférence
- Jamais la construction du prompt
- Jamais le parsing de la réponse
- Jamais l'écriture dans le journal
- Même principe appliqué identiquement à chaque appel, tour comme diagnostic

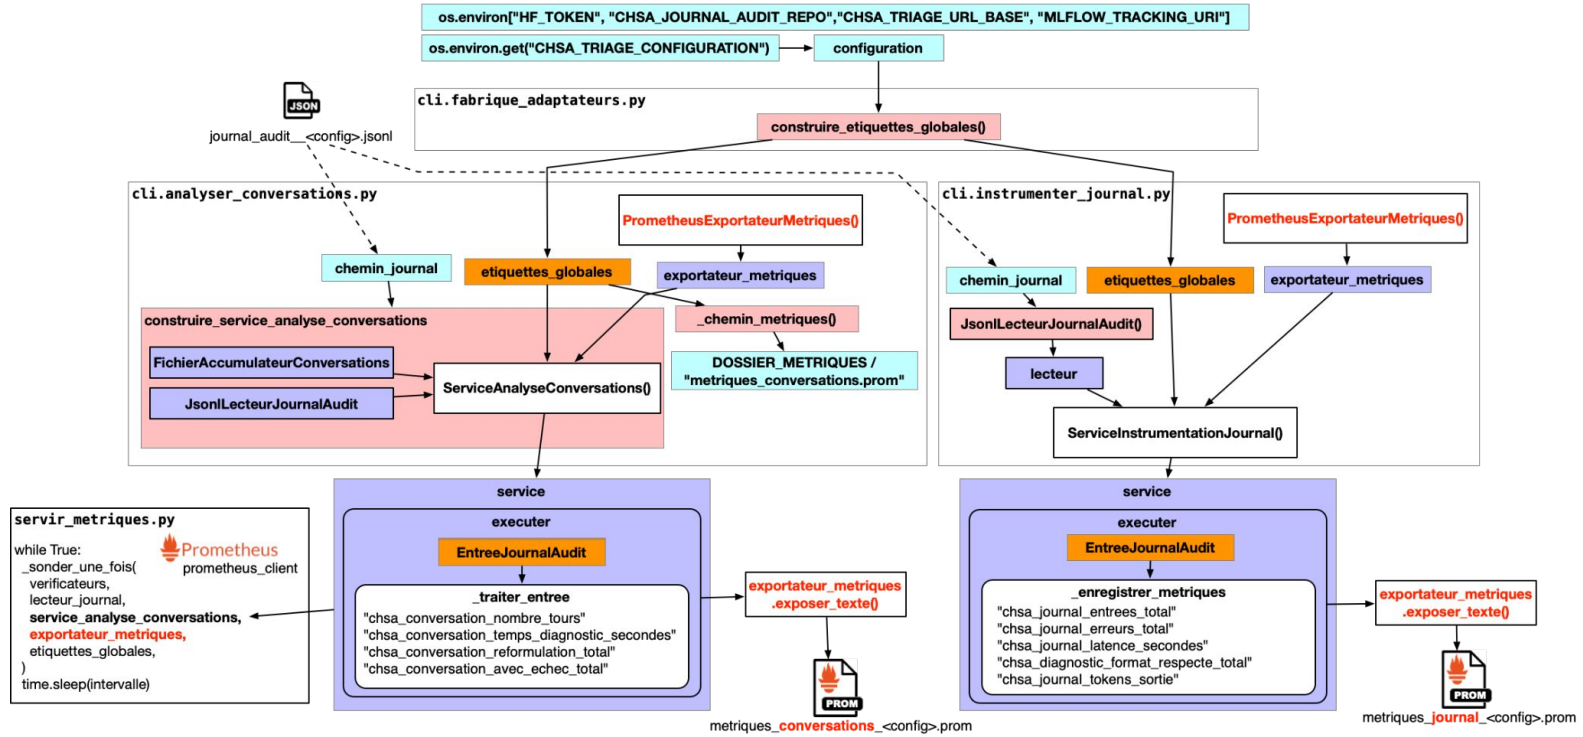


1. Introduction
2. Contexte
3. Diagnostic
4. Architecture cible
5. Garde-fous, Principe
6. Garde-fous, Diagramme
7. Mise en œuvre
8. Pilotage, Indicateurs
9. Pilotage, Dashboard
10. Bilan
11. Questions

Indicateurs

Architecture de câblage et de service :

- Le schéma ci-dessous détaille l'initialisation des adaptateurs et l'orchestration continue assurée par `servir_metriques.py` pour alimenter les métriques Prometheus.

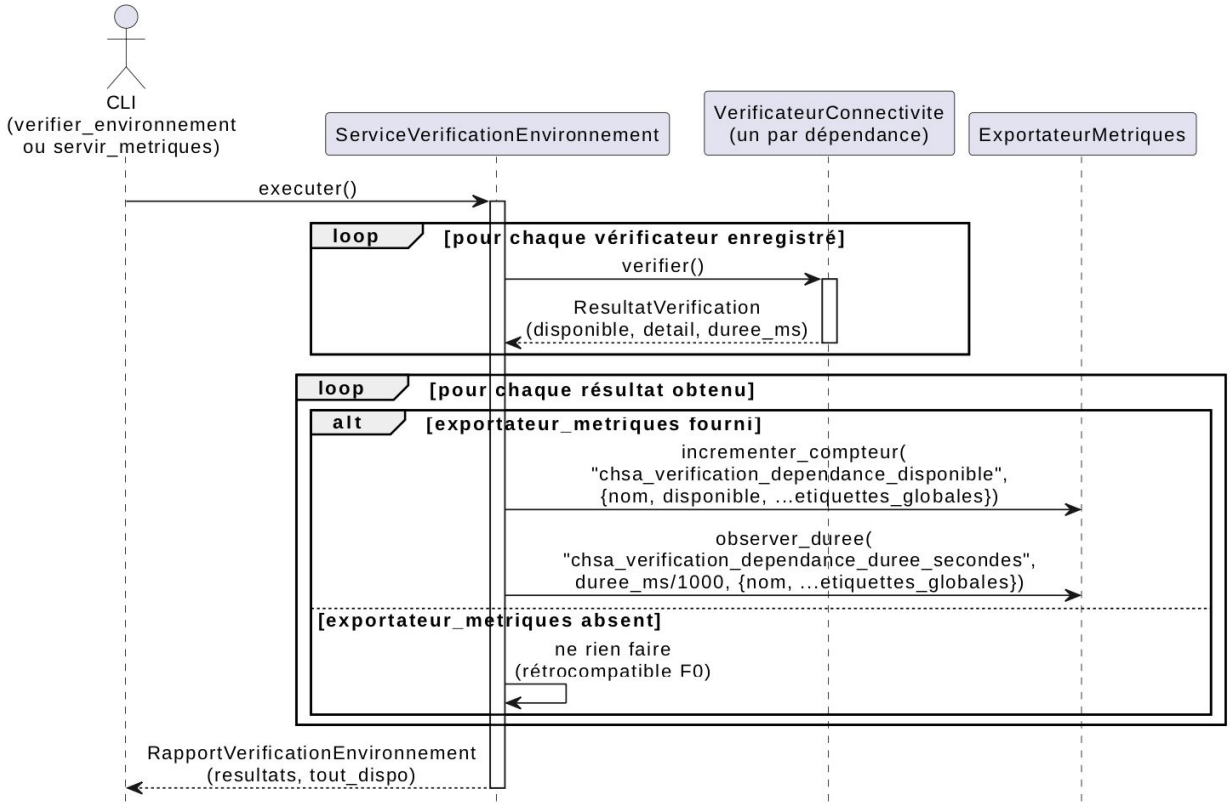


PILOTAGE

Indicateurs

Séquence : ServiceVerificationEnvironnement.executer() (F0/F1)

Vérification en boucle : La CLI déclenche l'exécution, interrogeant chaque vérificateur de connectivité enregistré pour obtenir l'état et la durée.
Exportation conditionnelle : Si l'exportateur de métriques est présent, les compteurs et durées sont enregistrés dans Prometheus (`chsa_verification_dependance_disponible` / `duree_secondes`) ; sinon, le système reste rétrocompatible (F0).

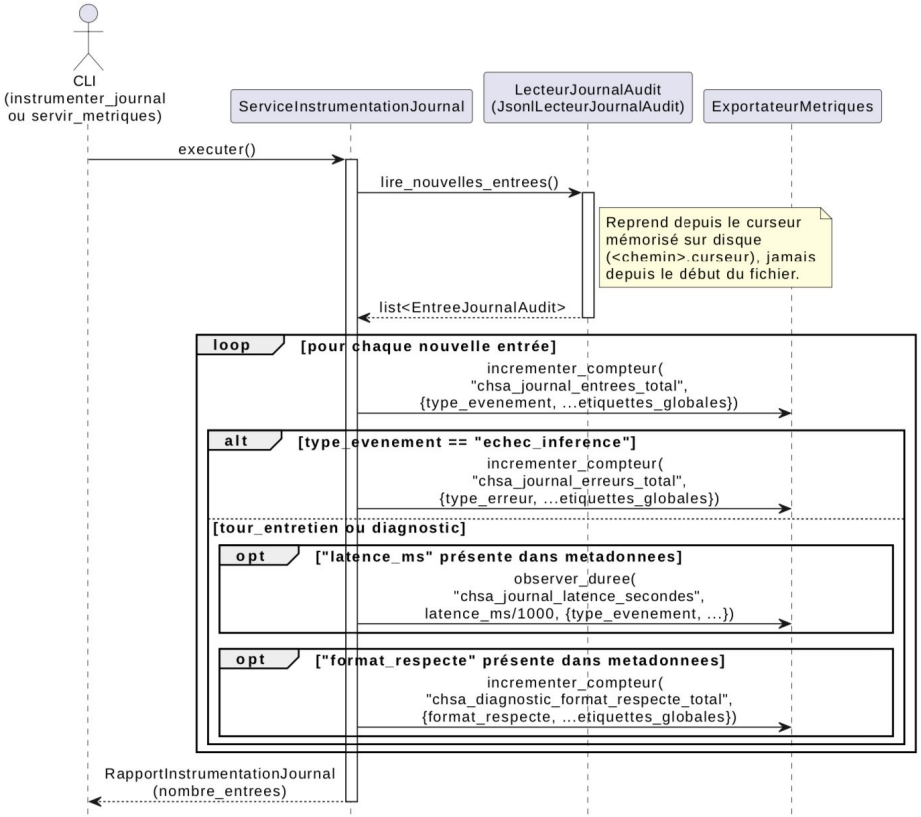


PILOTAGE

Indicateurs

Séquence : ServiceInstrumentationJournal.executer() (F2)

Lecture incrémentale : Reprend la lecture depuis le curseur mémorisé sur disque (<chemin>.curseur), garantissant qu'aucune entrée n'est comptée deux fois.
Traitement par événement : Analyse chaque nouvelle entrée pour incrémenter les compteurs globaux, les erreurs d'inférence, les durées de latence et la conformité du format du diagnostic.

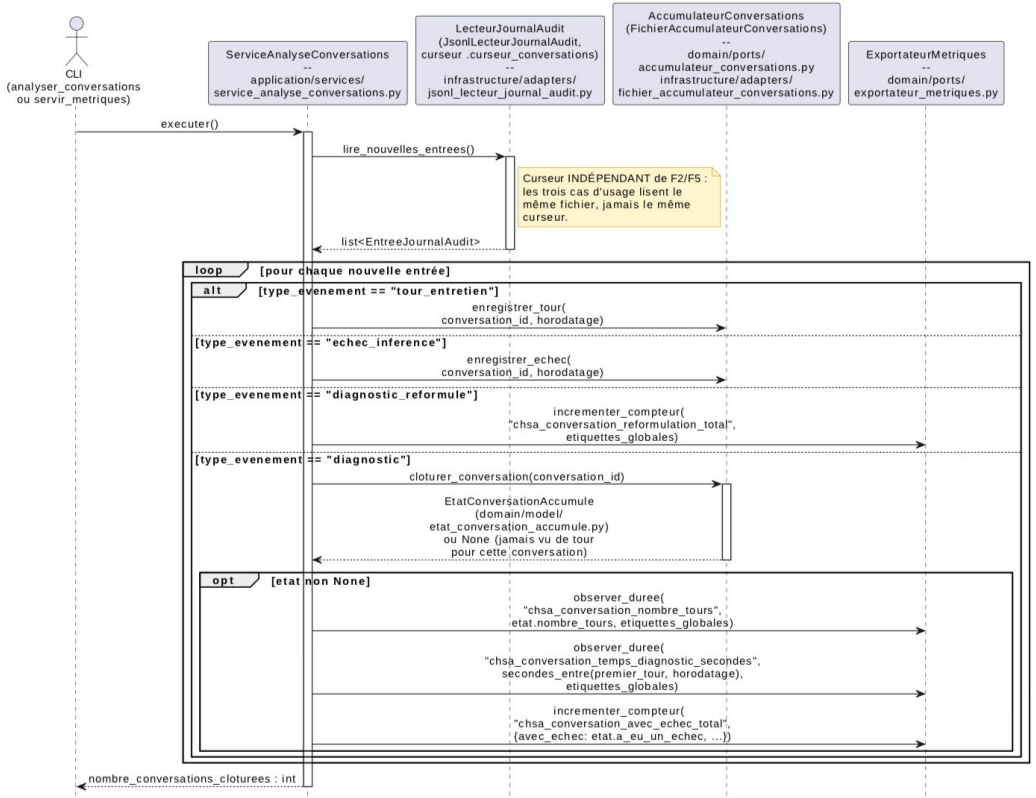


PILOTAGE

Indicateurs

Séquence : ServiceAnalyseConversations.executer() (F3)

Curseur indépendant : Utilise un curseur dédié (.curseur_conversations) pour lire le même fichier journal sans interférer avec les autres flux.
Agrégation par conversation : Traite chaque événement pour enregistrer les tours ou échecs, incrémenter les reformulations, et clôturer la conversation lors du diagnostic afin d'alimenter les métriques globales (chsa_conversation_nombre_tours, temps de diagnostic et échecs).



1. Introduction
2. Contexte
3. Diagnostic
4. Architecture cible
5. Garde-fous, Principe
6. Garde-fous, Diagramme
7. Mise en œuvre
8. Pilotage, Indicateurs
9. Pilotage, Dashboard
10. Bilan
11. Questions

PILOTAGE

Dashboard

Exemples de requêtes PromQL utilisées pour alimenter les graphiques et indicateurs du tableau de bord Grafana.

Code(s)	Panneau	Type	Formule (PromQL)
R9	Volume de requêtes	timeseries	sum(rate(chsa_journal_entrees_total{configuration=~"$configuration"}[5m])) by (type_evenement)
R1 + D2	Latence (p50/p95)	timeseries	histogram_quantile(0.50/0.95, sum(rate(chsa_journal_latence_secondes_bucket{configuration=~"$configuration"}[5m])) by (le, type_evenement))
R10	Taux d'échec d'inférence	stat	(sum(rate(chsa_journal_erreurs_total{configuration=~"$configuration"}[15m])) / sum(rate(chsa_journal_entrees_total{configuration=~"$configuration"}[15m]))) or vector(0)
D1	Respect du format de diagnostic	stat	(sum(chsa_diagnostic_format_respecte_total{configuration=~"$configuration", format_respecte="True"}) / sum(chsa_diagnostic_format_respecte_total{configuration=~"$configuration"})) or vector(0)
C6	Taux d'échec par conversation	stat	(sum(chsa_conversation_avec_echec_total{configuration=~"$configuration", avec_echec="True"}) / sum(chsa_conversation_avec_echec_total{configuration=~"$configuration"})) or vector(0)
C1	Nombre de tours avant diagnostic (médiane)	stat	histogram_quantile(0.50, sum(rate(chsa_conversation_nombre_tours_bucket{configuration=~"$configuration"}[30m])) by (le))
C2	Temps jusqu'au diagnostic (médiane)	stat	histogram_quantile(0.50, sum(rate(chsa_conversation_temps_diagnostic_secondes_bucket{configuration=~"$configuration"}[30m])) by (le))
C3	Taux de reformulation (par conversation)	stat	(sum(increase(chsa_conversation_reformulation_total{configuration=~"$configuration"}[1h])) / sum(increase(chsa_conversation_nombre_tours_count{configuration=~"$configuration"}[1h]))) or vector(0)
R2 + D3	Tokens de sortie (p50/p95)	timeseries	histogram_quantile(0.50/0.95, sum(rate(chsa_journal_tokens_sortie_bucket{configuration=~"$configuration"}[5m])) by (le, type_evenement))
X2	Coût estimé (indicatif)	timeseries	sum(increase(chsa_journal_tokens_sortie_sum{configuration=~"$configuration"}[1h])) by (type_evenement) * 0.000002 (exemple de tarif)

Centre Hospitalier
Saint-Aurélien (CHSA)

9

1. Introduction
2. Contexte
3. Diagnostic
4. Architecture cible
5. Garde-fous, Principe
6. Garde-fous, Diagramme
7. Mise en œuvre
8. Pilotage, Indicateurs
9. Pilotage, Dashboard
10. Bilan
11. Questions

PILOTAGE

Dashboard

1. 📦 Flux et Performance Globale
• Volume de requêtes (R9)
• Latence p50 / p95 (R1 + D2)
Objectif : Afficher le trafic global du système et les temps de réponse en temps réel.

2. 📦 Santé Clinique et Qualité des Conversations
• Taux d'échec d'inférence (R10)
• Respect du format de diagnostic (D1)
• Taux d'échec par conversation (C6)
• Nombre de tours avant diagnostic (C1)
• Temps jusqu'au diagnostic (C2)
• Taux de reformulation (C3)
Objectif : Regrouper tous les indicateurs clés de performance conversationnelle et clinique sur une seule bande horizontale.

3. 📦 Ressources et Coûts Opérationnels
• Tokens de sortie p50 / p95 (R2 + D3)
• Coût estimé indicatif (X2)
Objectif : Contrôler la consommation de tokens du LLM (Qwen) et l'estimation financière associée.

4. 📦 Sécurité et Garde-fous (F5)
• Score garde-fous, juge-LLM (D8)
• Alertes garde-fous / score sous seuil (D9)
Objectif : Isoler la couche de sécurité et de supervision rétrospective dans la partie inférieure.



BILAN

Ce qui est livré,
Ce qui reste un choix assumé

10

1. Introduction
2. Contexte
3. Diagnostic
4. Architecture cible
5. Garde-fous, Principe
6. Garde-fous, Diagramme
7. Mise en œuvre
8. Pilotage, Indicateurs
9. Pilotage, Dashboard
10. Bilan
11. Questions

✅ Livré

F0 → F3 et F5 en production

Tableau de bord Grafana, 12 panneaux

Garde-fou juge-LLM : local, gratuit, rétrospectif

⚠️ Limites assumées

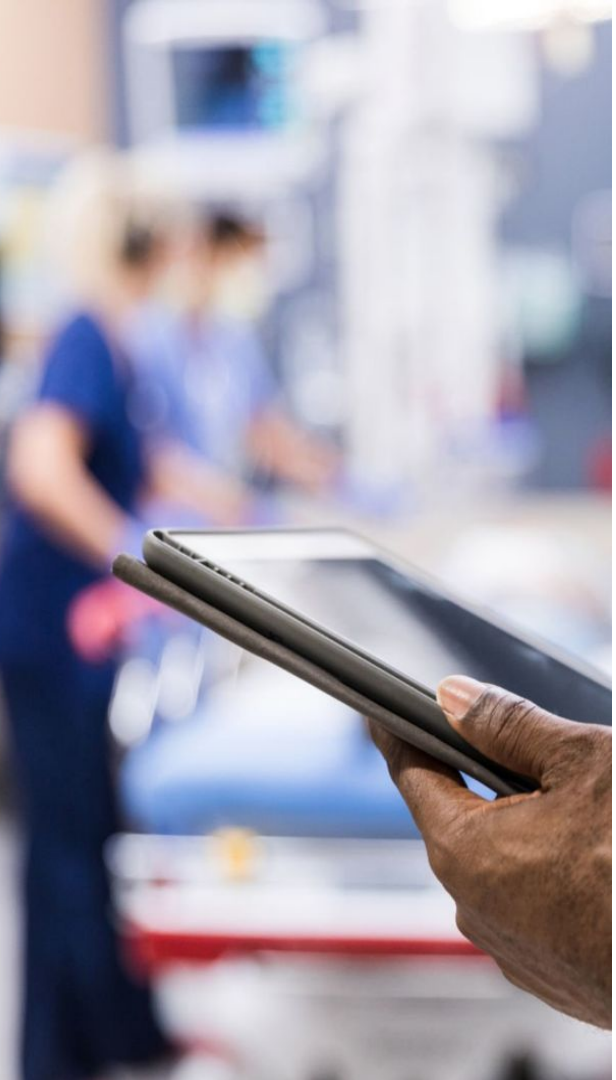
C5 (taux d'abandon) : non mesurable sans modifier m14_ocr

C7 (pertinence clinique) : hors périmètre — jamais confondu avec le garde-fou de forme

F4 (pertinence heuristique) : à planifier

- **Prochaine étape recommandée :**

F4, puis un chantier de pertinence clinique séparé, par lots, avec révision humaine.



Q et R

Rafael CEREZO MARTIN

Octobre 2026